



Universidade Federal de Pernambuco  
Centro de Informática

Bacharelado em Ciência da Computação

**Análise de extensão do CSDiff para uso  
em linguagens com poucos separadores  
sintáticos**

José Gabriel Silva Pereira

Dissertação de Mestrado

Recife  
27 de Abril de 2023

Universidade Federal de Pernambuco  
Centro de Informática

José Gabriel Silva Pereira

## **Análise de extensão do CSDiff para uso em linguagens com poucos separadores sintáticos**

*Trabalho apresentado ao Programa de Bacharelado em Ciência da Computação do Centro de Informática da Universidade Federal de Pernambuco como requisito parcial para obtenção do grau de Mestre em Ciência da Computação.*

Orientador: *Paulo Henrique Monteiro Borba*  
Co-orientadora: *Paola Rodrigues de Godoy Accioly*

Recife  
27 de Abril de 2023

# Resumo

A prática de desenvolvimento de software, há muito tempo deixou de ser uma tarefa que era realizada por somente uma pessoa, pois, com o avanço da tecnologia, sistemas cada vez mais complexos foram sendo criados fazendo com que muitas pessoas trabalhassem no mesmo projeto. Por conta disso, ferramentas de controle de versionamento de código foram criadas, permitindo que múltiplos desenvolvedores trabalhassem modificando o mesmo trecho de código simultaneamente. Porém, essas modificações simultâneas podem gerar conflitos quando feitas em um mesmo pedaço de código, o que impacta negativamente na produtividade de um time. Ao decorrer do tempo, diversas formas de como detectar conflitos na junção de versão de códigos foram criadas, dentre elas: linha a linha, estruturada e semiestruturada. Neste trabalho, é proposto uma extensão para uma ferramenta semiestruturada de detecção de conflitos já existente, o *CSDiff* [1], de forma que ela utilize indentação como separador da linguagem, permitindo assim que, durante a detecção de conflitos em linguagens com poucos separadores sintáticos, ainda seja possível permitir uma redução de falsos conflitos, consequentemente melhorando a produtividade de um time.

**Palavras-chave:** Processo de Merge, Desenvolvimento Colaborativo, Merge Textual, Merge Estruturado, Separadores sintáticos

# Abstract

The practice of software development has long ceased to be a task performed by only one person, as with the advancement of technology, increasingly complex systems have been created, causing many people to work on the same project. Therefore, code version control tools were created, allowing multiple developers to work on modifying the same piece of code simultaneously. However, these simultaneous modifications can generate conflicts when made on the same piece of code, negatively impacting a team's productivity. Over time, several ways of detecting conflicts in the merging of code versions have been created, including line-by-line, structured, and semi-structured. In this work, an extension is proposed for an existing semi-structured conflict detection tool, the *CSDiff* [1], so that it uses indentation as a language separator, thus allowing a reduction in false conflicts during conflict detection in languages with few syntactic separators, consequently improving a team's productivity.

**Keywords:** Merge Process, Collaborative Development, Textual Merge, Structured Merge, Syntactic Separators.

## CAPÍTULO 1

# Introdução

Com o crescimento da complexidade dos sistemas de software, surge a necessidade de que múltiplas pessoas trabalhem num mesmo projeto. Essas modificações, com o objetivo de trazer mais produtividade, costumam ser executadas de forma paralela e podem acontecer em trechos de código em comum. Tendo como objetivo auxiliar os desenvolvedores a controlar e versionar suas modificações no código, ferramentas de controle de versão de código foram criadas. Essas ferramentas auxiliam a reduzir o trabalho extra quando se trata de modificações paralelas que precisam ser unidas. O processo de unir duas modificações paralelas de código é chamado de *merge* [2].

No processo de *merge*, quando dois desenvolvedores modificam o mesmo trecho de código e essas mudanças interferem uma na outra, é gerado um conflito. Esses conflitos, quando detectados, algumas vezes precisam ser resolvidos por um ou ambos os desenvolvedores, o que acaba impactando na produtividade, dado que resolvê-los geralmente é uma tarefa que geralmente demanda tempo [3]. Além do impacto na produtividade do time, quando esses conflitos não são detectados pela ferramenta de *merge*, ou quando são detectados e mal resolvidos, eles podem levar à introdução de bugs dentro do código, o que influencia na qualidade do produto final [4].

A abordagem de *merge* mais utilizada na indústria atualmente é o *merge* não estruturado [5], que se utiliza de uma análise puramente textual, equiparando linha a linha trechos do código para detectar e resolver conflitos. Porém, por não utilizar a estrutura do código que está sendo integrado, por muitas vezes essa abordagem gera falsos conflitos. Ao observar isso, pesquisadores propuseram ferramentas que se baseiam na estrutura dos arquivos que estão sendo integrados, criando uma árvore sintática a partir do texto dos arquivos e de sua linguagem de programação [6]. Essas abordagens são chamadas estruturadas e semiestruturadas.

Estudos anteriores [6]–[8] compararam as duas abordagens (estruturada e semiestruturada) em relação à não estruturada e mostraram que, para a maioria das situações de *merge* dos projetos, houve uma redução de conflitos em favor da semi ou da estruturada. Essa redução se dá por conta de falsos conflitos que possuem resolução óbvia, como por exemplo, quando os desenvolvedores adicionam dois métodos diferentes e independentes numa mesma região do código [9].

Esse benefício advém da exploração da estrutura gerada pela análise sintática, também chamada de análise gramatical. Ela envolve o agrupamento dos tokens (palavras) do programa fonte em frases. Cada linguagem possui conjuntos de tokens, onde alguns servem como divisores de elementos sintáticos e escopo semântico, como por exemplo as chaves ('', '') numa linguagem como Java. Estes tokens, especificamente, são definidos aqui simplesmente como **separadores** sintáticos.

A solução não estruturada mais utilizada, o Diff3, se baseia somente na quebra de linha como o divisor de contexto para detecção de conflitos. Assim, o algoritmo de *merge* compara as linhas mantidas, adicionadas, e removidas por cada desenvolvedor e, com base nisso, reporta conflito quando as mudanças ocorrem em uma mesma área do texto, isto é, quando não há uma linha mantida que separa as mudanças feitas por um desenvolvedor das mudanças feitas pelo outro.

Como forma de melhorar os resultados do Diff3, o CSDiff, proposto em trabalhos anteriores, utiliza-se dos separadores mencionados acima para dividir o contexto de cada linha de código. Assim, o algoritmo de *merge* consegue, por exemplo, resolver conflitos em uma mesma linha, contanto que esses conflitos estejam separados por pelo menos um dos separadores definidos.

Contudo, o CSDiff possui limitações, pois linguagens como Python, possuem poucos separadores (seu principal separador é a própria indentação do código, que não é considerado pelo CSDiff atual). Este trabalho propõe uma modificação para o CSDiff, que utiliza a indentação como um separador sintático, de forma a tentar resolver esse problema, e analisa os resultados em comparação ao *merge* não estruturado puramente textual. Em particular, investiga-se as seguintes perguntas de pesquisa:

- 1) PP1: A nova solução de *merge* não estruturado, utilizando indentação, reduz a quantidade de conflitos reportados em comparação ao *merge* puramente textual?
- 2) PP2: A nova solução de *merge* não estruturado, utilizando indentação, reduz a quantidade de cenários com conflitos reportados em comparação ao *merge* puramente textual?
- 3) PP3: A nova solução de *merge* não estruturado, utilizando indentação, reduz a quantidade de falsos conflitos e cenários com falsos conflitos reportados (falsos positivos) em comparação ao *merge* puramente textual?
- 4) PP4: A nova solução de *merge* não estruturado, utilizando indentação, amplia a possibilidade de comprometer a corretude do código, por aumentar o número de integrações de mudanças que interferem uma na outra, sem reportar conflitos (falsos negativos), além de aumentar cenários com falsos negativos?
- 5) PP5: A nova solução de *merge* não estruturado, utilizando indentação, demonstra um aumento de produtividade considerando o ato de resolver conflitos de *merge*?

Os resultados obtidos mostram que além de aumentar a quantidade de conflitos reportados (como esperado considerando os resultados dos trabalhos anteriores), o *merge* não estruturado utilizando separadores e indentação, demonstra, para a amostra utilizada, um aumento de aFN proporcional a quantidade de aFP reduzido quando comparado ao Diff3. Vale ressaltar que isso foi observado considerando a amostra sem um dos projetos utilizados - o matplotlib - que por ter uma quantidade muito grande de conflitos por cenário/arquivo, se tornou um ponto fora da curva ao considerar criação de aFP. Por outro lado, ao se fazer a análise de aumento de produtividade considerando o ato de resolver e reduzir conflitos, além de considerar geração de conflitos extras e resolução errada de conflitos, notou-se um bom aumento de produtividade com a utilização do CSDiff. Os conceitos utilizados para esta análise são explicados no capítulo (TODO: adicionar capítulo/secao aqui).

## CAPÍTULO 2

# Motivação

### 2.1 Merge Não Estrurado

Apesar da evolução dos sistemas de controle de versão, as ferramentas utilizadas para realizar *merge* não evoluíram tanto. A ferramenta mais utilizada atualmente é o *diff3* [2], que consiste em uma abordagem puramente textual baseada em linhas. Essa ferramenta, ao receber os três arquivos que configuram o cenário de merge (chamemos de *base*, *left* e *right*), compara, linha a linha, as duas versões modificadas (*left* e *right*) com seu ancestral comum (*base*), que foi o arquivo que deu origem às modificações que vão ser integradas. Após isso, a ferramenta agrupa as maiores áreas em comum e checka se existem interseções entre as áreas modificadas por *left* e *right*. Essas interseções são definidas como conflitos de merge [5], elas serão sinalizadas pelo *diff3* através de marcadores ( ">>>>>>>", "=====", "<<<<<<<" ), como demonstrado na Figura 2.4.

Por considerar as mudanças linha a linha para detectar os conflitos, muitas vezes essa ferramenta relata falsos conflitos de modificações que alteram a mesma linha ou linhas consecutivas, mas que não interferem entre si semanticamente. Esse problema poderia ser resolvido utilizando ferramentas que explorem a estrutura sintática do código em questão.

Para ilustrar esse problema causado pelo *merge* não estruturado, utilizamos a implementação de um método `to_string` que recebe uma lista de strings e retorna uma string juntando todos os elementos da lista separados por dois *underlines* `"__"`. Observe que as mudanças feitas pelo *left* foram a adição de uma nova condição no `if`, e a mudança da string separadora do `return` final (modificado de `".."` para `"__"`). Por outro lado, as mudanças feitas pelo *right* foram o valor padrão de retorno de uma string vazia para uma constante (por simplicidade consideramos que a constante foi definida na classe onde o método está sendo implementado), e a mesma modificação que o *left* fez no último `return` do método. Perceba que todas essas mudanças são independentes entre si, mas por elas acontecerem em linhas consecutivas, o *diff3* relata todas elas em um mesmo conflito (Figura 2.4).

```
1 def to_string(l: List[str]) -> str:
2     if len(l) == 0:
3         return ""
4     return "..".join(l)
```

**Figura 2.1** Arquivo *base* que contém o método `to_string`

```
1 def to_string(l: List[str]) -> str:
2     if l is null or len(l) == 0:
3         return ""
4     return "__".join(l)
```

**Figura 2.2** Arquivo *left* que contém o método `to_string`

```
1 def to_string(l: List[str]) -> str:
2     if len(l) == 0:
3         return self.D
4     return "__".join(l)
```

**Figura 2.3** Arquivo *right* que contém o método `to_string`

## 2.2 Merge Semiestruturado e Estruturado

Como alternativa ao uso de merge não estruturado, existem as abordagens semiestruturadas ou completamente estruturadas. Ao contrário da abordagem não estruturada, essas abordagens levam em consideração a estrutura sintática da linguagem de programação para identificar conflitos com maior precisão e resolvê-los de forma mais correta. Essas abordagens criam árvores sintáticas para cada versão dos arquivos a serem integrados (*base*, *left* e *right*) e comparam essas árvores para identificar nós comuns e adições ou remoções em cada árvore. Dessa forma, cada elemento sintático é representado em nós distintos, e conflitos são sinalizados quando as mudanças a serem integradas estão relacionadas ao mesmo nó da árvore. Isso significa que, em vez de usar linhas como a unidade básica para comparação, essas ferramentas usam nós sintáticos como unidade.

Essas ferramentas estruturadas e semiestruturadas conseguem evitar falsos conflitos encontrados na abordagem não estruturada. Por exemplo, duas situações em que dois desenvolvedores adicionam separadamente dois novos métodos com diferentes assinaturas em uma mesma área do texto podem ser conciliadas com sucesso. As mudanças ocorrem na mesma linha, mas cada declaração é representada por um nó diferente, pois o identificador do método é parte do nó, e os dois nós são mantidos na árvore resultante da integração.

Dessa forma, é fácil observar que uma ferramenta estruturada para Python evitaria o conflito apresentado na Figura 2.4. A ferramenta, utilizando a estrutura da linguagem, identificaria que, apesar das mudanças representadas na Figura 2.2 e na Figura 2.3 ocorrerem em linhas consecutivas (o que faz com que o *diff3* agrupe as mudanças em um único bloco de conflito), elas estariam associadas a nós diferentes na árvore sintática. A ferramenta então juntaria as mudanças em uma versão resultante que contém a nova condição proposta por *left* e o novo valor de retorno proposto por *right*, evitando o falso conflito.



```
1 def to_string(l: List[str]) -> str:
2 <<<<<<< ./left.py
3     if l is null or len(l) == 0:
4         return ""
5     return "__".join(l)
6 =====
7     if len(l) == 0:
8         return self.D
9     return "__".join(l)
10 >>>>>>> ./right.py
```

**Figura 2.4** Resultado de executar o *diff3*

## 2.3 Merge não Estruturado com separadores

As abordagens estruturadas e semiestruturadas discutidas na seção anterior, apesar de claramente benéficas, possuem um custo adicional, dado que elas se baseiam em manipulação de árvores sintáticas, que por sua vez são dependentes da linguagem em questão e demandam um esforço significativo de implementação por linguagem, além de que a manipulação das árvores sintáticas possui um custo computacional maior em relação a abordagens puramente textuais.

Em trabalhos anteriores, Clementino, Borba e Cavalcanti propuseram uma nova ferramenta chamada **Custom Separators Diff** (*CSDiff*), cujo funcionamento baseia-se na abordagem puramente textual, mas que também considera a estrutura sintática do programa por meio de um conjunto de separadores da linguagem, escolhidos pelo usuário e passados como parâmetro.

## CAPÍTULO 3

# Solução

### 3.1 CSDiff

### 3.2 Implementação

## CAPÍTULO 4

# Avaliação

### 4.1 CONCEITOS

#### 4.1.1 Cenário de Merge

#### 4.1.2 Falso Positivo Adicionado

#### 4.1.3 Falso Negativo Adicionado

#### 4.1.4 Resultado Errado de Merge

### 4.2 PERGUNTAS DE PESQUISA

**4.2.1 A nova solução de merge não estruturado, utilizando separadores, reduz a quantidade de conflitos reportados em comparação ao merge puramente textual?**

**4.2.2 A nova solução de merge não estruturado, utilizando separadores, reduz a quantidade de cent'ários com conflitos reportados em comparação ao merge puramente textual?**

**4.2.3 A nova solução de merge não estruturado, utilizando separadores, reduz a quantidade de falsos conflitos e cent'ários com falsos conflitos reportados (falsos positivos) em comparação ao merge puramente textual?**

**4.2.4 A nova solução de merge não estruturado, utilizando separadores, amplia a possibilidade de comprometer a corretude do código, por aumentar o número de integrações de mudanças que interferem uma na outra, sem reportar conflitos (falsos negativos), além de aumentar cent'ários com falsos negativos?**

#### **4.2.5 PP5 sobre aumento de produtividade**

TODO: adicionar uma subsubsection pra cada possível situação desse role, após explicar o role

### **4.3 METODOLOGIA**

### **4.4 RESULTADOS**

TODO: copiar as subsections do perguntas de pesquisa aqui

### **4.5 DISCUSSÃO**

### **4.6 AMEAÇAS A VALIDADE**

## CAPÍTULO 5

# **Trabalhos Relacionados**

## CAPÍTULO 6

# **Conclusão**

# Bibliografia

- [1] J. Clementino, P. Borba e G. Cavalcanti, “Textual merge based on language-specific syntactic separators,” em *35th Brazilian Symposium on Software Engineering (SBES 2021)*, 2021, pp. 243–252.
- [2] T. Mens, “A state-of-the-art survey on software merging,” *IEEE Transactions on Software Engineering*, v. 28, n. 5, pp. 449–462, 2002. DOI: 10.1109/TSE.2002.1000449.
- [3] Y. Brun, R. Holmes, M. D. Ernst e D. Notkin, “Proactive Detection of Collaboration Conflicts,” em *Proceedings of the 19th ACM SIGSOFT Symposium and the 13th European Conference on Foundations of Software Engineering*, sér. ESEC/FSE ’11, Szeged, Hungary: Association for Computing Machinery, 2011, pp. 168–178, ISBN: 9781450304436. DOI: 10.1145/2025113.2025139. endereço: <https://doi.org/10.1145/2025113.2025139>.
- [4] C. Brindescu, I. Ahmed, C. Jensen e A. Sarma, “An empirical investigation into merge conflicts and their effect on software quality,” *Empirical Software Engineering*, v. 25, n. 1, pp. 562–590, 2020.
- [5] S. Khanna, K. Kunal e B. C. Pierce, “A formal investigation of diff3,” em *International Conference on Foundations of Software Technology and Theoretical Computer Science*, Springer, 2007, pp. 485–496.
- [6] S. Apel, J. Liebig, B. Brandl, C. Lengauer e C. Kästner, “Semistructured Merge: Rethinking Merge in Revision Control Systems,” em *Proceedings of the 19th ACM SIGSOFT Symposium and the 13th European Conference on Foundations of Software Engineering*, sér. ESEC/FSE ’11, Szeged, Hungary: Association for Computing Machinery, 2011, pp. 190–200, ISBN: 9781450304436. DOI: 10.1145/2025113.2025141. endereço: <https://doi.org/10.1145/2025113.2025141>.
- [7] G. Cavalcanti, P. Accioly e P. Borba, “Assessing Semistructured Merge in Version Control Systems: A Replicated Experiment,” em *2015 ACM/IEEE International Symposium on Empirical Software Engineering and Measurement (ESEM)*, 2015, pp. 1–10. DOI: 10.1109/ESEM.2015.7321191.
- [8] G. Cavalcanti, P. Borba, G. Seibt e S. Apel, “The Impact of Structure on Software Merging: Semistructured Versus Structured Merge,” em *2019 34th IEEE/ACM International Conference on Automated Software Engineering (ASE)*, 2019, pp. 1002–1013. DOI: 10.1109/ASE.2019.00097.

- [9] G. Cavalcanti, P. Borba e P. Accioly, “Evaluating and Improving Semistructured Merge,” *Proc. ACM Program. Lang.*, v. 1, n. OOPSLA, out. de 2017. DOI: 10.1145/3133883. endereço: <https://doi.org/10.1145/3133883>.